

从离散示范点到连续可行域

连续可接受状态集合、成功概率场与多解动作分布的监督学习研究

核心结论：用户提出的问题不是单纯的“输出多模态”。更完整的数学对象是状态—动作（或状态—轨迹）空间上的连续成功概率场。可接受释放状态和可行动作分别是该概率场的超水平集；在这些集合内部，策略还需要表示多条都能成功的轨迹。普通单示范行为克隆只学习专家访问并选择过的点，不能从有限点样本识别完整可行域。

任务背景：一台 Panthera 机械臂、一个夹爪，将圆柱放入凹槽

检索日期：2026-09-24 (Asia/Shanghai)

方法修订：2026-09-24；逐篇补充问题定义、模型、损失和数据构造

原文归档：docs/references/papers/continuous_feasible_distributions/

证据性质：文献调查与待验证方案；没有在本报告中启动训练或真机实验

摘要

本报告从问题本身出发，而不是预先假定某个机器人模型或训练方法。第一层问题是：给定物理状态，哪些动作或未来轨迹能够成功？第二层问题是：哪些邻近状态都允许执行“释放”并最终入槽？第三层问题是：如何从图像观测和机器人状态学习这些连续对象。条件密度估计、集合值回归、可生存状态—动作集合和可行性学习分别提供了部分答案；能量模型、条件生成模型和扩散策略则提供了表示多解动作分布的工具。

文献支持把 Panthera 的目标写成 成功概率场 $\rightarrow$ 可接受区域 $\rightarrow$ 区域内动作分布 三层，而不是把每张图像强制回归到唯一专家动作。不同研究对训练数据的处理并不相同。混合密度网络、Multiple Choice Learning 和条件变分自编码器可以直接使用普通输入—输出样本，只改变模型输出和损失；Implicit Behavioral Cloning 会为专家动作生成对比负样本，Diffusion Policy 会把示范切成时间窗口并向动作块加入训练噪声；真正学习“哪些邻近状态—动作都可行”的工作则需要规划器、仿真器或环境额外返回可行/失败标签。最接近用户设想的 Theile 等不是对专家轨迹做简单增强，而是反复查询可行性函数，并让生成器匹配全部可行动作组成的目标分布。

有限数据集始终由离散记录组成。“连续”来自模型对连续坐标定义函数或密度，以及采样对目标邻域的覆盖，不是把数据文件本身变成连续对象。仅有一条专家轨迹时，“专家只展示了一个选择”和“实际上只有一个可行选择”在数据上不可区分。因此，如果要学习完整可行域，必须额外查询仿真结果、规划器、接触/几何判据，或者为同一邻域收集多个成功与失败后继。

1 先把问题说准确

设 s 是完整物理状态，例如圆柱相对槽的位置和姿态、末端位姿、关节速度、夹爪开度与接触状态； a 是一个动作块或短轨迹； $Y=1$ 表示执行后满足“圆柱稳定入槽并解除夹持”。用户的想法可写成：

联合成功概率场：

$$g(s, a) = P(Y = 1 \mid s, a)$$

g 不是给每个状态指定唯一动作，而是给每个状态—动作组合一个成功概率。由它可以导出两个集合：

可接受释放状态： $S_\tau = \{s : P(Y=1 \mid s, \text{execute release}) \geq \tau\}$

状态 s 下的可行动作： $A_\tau(s) = \{a : g(s, a) \geq \tau\}$

第一式表达“末端不必精确位于一个点，只要落在允许释放的连续区域内即可”；第二式表达“同一状态下向左或向右绕行都可能成功”。这比“输入和输出都有噪声”更准确，因为研究对象是可接受集合及其内部结构。

集合不自动等于概率分布。 一个可接受区域只回答成员关系。要把它变成概率密度，还必须说明如何在区域内加权。例如可以从基础采样密度 $p_\theta(s)$ 出发，定义 $q(s) \propto p_\theta(s) \cdot w(g(s))$ 。若不指定 p_θ 和权重函数，所谓“可接受输入分布”并不唯一。

相机图像也不是独立的三维空间。若 o 是图像、 c 是相机参数，那么图像分布由物理状态与相机投影共同产生：

$$q_O(o) = \int p(o | s, c) q_S(s) p(c) ds dc$$

因此，像素上“接近”不保证物理状态接近；相同物理状态在不同相机下也会形成不同像素。仿真中应先用物理状态定义成功与可接受区域，再把该分布渲染为训练图像，而不是直接在 RGB 像素上画欧氏邻域。

2 检索路线：没有从机器人术语开始

检索按数学对象逐层展开，避免先假定“这就是扩散策略”“这就是强化学习”：

检索层	一般问题	代表关键词	保留的研究线
条件输出	一个输入是否可以对应多个连续输出？	conditional density、multivalued regression、multifunction	混合密度网络、条件密度估计、集合值回归
连续区域	如何表示“答案位于一片区域”而非一个点？	density level set、prediction region、superlevel set	条件密度超水平集、直接区域回归
状态—动作集合	哪些状态仍存在成功后继，哪些动作保持可行？	viability kernel、state-action feasible set、reachability	可生存核、安全/可行状态—动作集合
监督来源	不做在线奖励优化，怎样得到可行性标签？	learned feasibility、planner oracle、outcome supervised	规划器/仿真器查询、成功失败分类
机器人策略	怎样生成多条连贯的有效动作序列？	multimodal imitation、energy policy、generative policy	隐式行为克隆、条件生成模型、扩散动作序列

完整原文、来源和哈希见论文索引。检索得到的研究不是单一路线：有些估计概率密度，有些直接估计集合边界，有些只学习可行性分类器，有些生成多个输出。报告后文把这些对象分开，避免把“预测不确定性”“可行域”“专家偏好”和“随机策略”混成同一件事。




图 1 用户想法的三个不同数学对象及其依赖关系

3 先用同一套问题阅读每种方法

下面不再只列方法名称。每种方法都回答五个固定问题：一条训练记录包含什么；模型接收什么；模型输出什么；损失怎样训练该输出；部署时怎样得到动作或集合。表 1 先给出全貌，后续小节再展开公式和数据流程。

方法	论文定义的问题与模型输出	训练数据和处理	是否能识别未示范可行域
混合密度网络 (MDN) [1]	学习 $p(y x)$ ；网络输出每个高斯分量的权重、均值和方差	普通成对样本 (x,y) ；用负对数似然训练，无需额外标签	不能；只拟合样本分布中已经出现的分支
集合值/条件模态回归 [3,5]	估计条件密度，并返回每个 x 下的一个或多个局部模态	普通成对样本；核密度方法会按 x 和 y 邻近性加权	不能；平滑和带宽只是结构假设
Multiple Choice Learning (MCL) [7]	一次输出 M 个候选，集合损失只计算最接近标签的候选	普通成对样本；一条记录只有一个真值也可训练	不能；未被最佳候选使用的输出不保证可行
条件变分自编码器 (CVAE) [8]	学习带潜变量 z 的 $p(y x,z)$ ；改变 z 可生成不同输出	普通成对样本；训练时额外从近似后验采样 z	不能；生成范围仍由训练输出决定
Implicit Behavioral Cloning (IBC) [12]	学习状态—动作能量 $E(o,a)$ ；低能量动作是候选策略	专家动作作为正样本，训练时为每个观测生成多个动作负样本	通常不能；未展示但可行的动作可能被当作负样本
Diffusion Policy[13]	学习 $p(A_t O_{1:t})$ ；从噪声迭代生成完整动作块	示范切成观测历史和未来动作块；随机向动作块加扩散噪声	不能；噪声是数值训练机制，不是物理成败标签
条件密度超水平集 [15,16]	估计条件密度后，返回包含指定概率质量的高密度区域	普通观测样本；拟合混合分布或直接学习区域边界	只有被估计的密度本身就是成功概率时才接近可行域
规划器可行性分类[10]	输入场景几何，输出某个运动规划问题可行/不可行	专门运行规划器产生二分类标签；不是示范动作数据	可以近似规划器标出的区域，但受查询覆盖和误标影响

方法	论文定义的问题与模型输出	训练数据和处理	是否能识别未示范可行域
可生存状态—动作集合[11]	学习哪些 (s,a) 会转移到仍可避免失败的状态，并计算可行动作体积	主动执行动作，保存 $(s,a,s',failed)$	可以近似安全/可生存域；不等同于任务成功域
全部可行动作生成[14]	给定二值可行函数 $g(s,a)$ ，学习覆盖 $A^+(s)$ 的条件生成器	对同一状态查询多个动作；可直接查仿真函数，或用成败回放训练 critic	最接近本问题；能否覆盖取决于可行性查询和采样覆盖

一个必须先纠正的表述。 推理时模型收到的是一次具体观测 x ，不是把一个概率分布整体塞进网络。概率分布描述训练样本如何产生，或者描述给定 x 后哪些输出具有多大概率。“附近哪些输入都允许释放”则应表示成定义在连续状态上的成功函数及其阈值集合，而不只是输入随机变量 X 。

4 只改输出模型：数据集可以保持普通成对样本

4.1 混合密度网络：输出一组分布参数

MDN 的一条训练记录仍是 (x_i, y_i) 。网络不再直接输出一个预测值，而是输出 K 个混合权重 $\alpha_k(x)$ 、均值 $\mu_k(x)$ 和协方差 $\Sigma_k(x)$ ：

$$p(y|x) = \sum_{k=1..K} \alpha_k(x) \cdot N(y; \mu_k(x), \Sigma_k(x))$$

$$L = -\sum_i \log p(y_i|x_i)$$

训练损失要求观测到的 y_i 在预测分布下具有高概率。若相近的 x 在数据里对应多个不同的 y ，不同混合分量可以覆盖不同分支；平方误差则倾向输出这些分支的平均值。论文无需为每个 x 列出全部答案，也没有把数据集改造成可行/不可行分类数据[1]。因此，MDN 解决的是“如何表示示范分布的一对多”，没有回答“示范外的动作是否也成功”。

4.2 MCL：保证候选集合里至少有一个接近标签

MCL 为每个输入产生 M 个候选 $\{\hat{y}_1, \dots, \hat{y}_M\}$ ，并使用 hindsight/oracle set loss：

$$L_{\text{set}}(x_i, y_i) = \min_{m=1..M} \ell(y_i, \hat{y}_{im})$$

只有当前最接近标签的候选承担该样本的任务损失，所以多个预测器会像聚类中心一样分工。训练集仍可只有普通单真值样本[7]。这种目标适用于“后续用户或模块能从候选中挑出最好一个”的场景；它不要求其他 $M-1$ 个候选正确，也没有给每个候选分配成功概率。因此，MCL 证明监督学习可以输出集合，却不能单独用作 Panthera 的可行性判定器。

4.3 CVAE：用潜变量索引同一输入下的多种输出

CVAE 把输入记为 x 、输出记为 y 、潜在选择记为 z 。训练时，识别网络 $q\phi(z|x,y)$ 看见输入和真值输出；条件先验 $p\theta(z|x)$ 只看输入；生成网络 $p\theta(y|x,z)$ 用二者生成输出。优化目标包含重建项和 KL 项：

$$\text{ELBO} = E_{q\phi(z|x,y)}[\log p\theta(y|x,z)] - \text{KL}(q\phi(z|x,y) \parallel p\theta(z|x))$$

部署时没有真值 y ，从 $p\theta(z|x)$ 采样不同 z ，再生成不同输出[8]。训练数据仍是普通 (x,y) ；论文中的遮挡噪声是语义分割实验的正则化技巧，不是 CVAE 表达多解所必需的可行性标签。与 MDN 一样，CVAE 学到的是数据中的输出变化。

4.4 集合值回归：返回条件密度的多个峰

Einbeck 与 Tutz 先用核函数估计 $f(y|x)$ ，再寻找对固定 x 而言所有局部最大值，将它们作为集合值回归结果[3]。这里的“连续”来自核函数和带宽：附近样本对当前 x 的估计贡献更大。Sugiyama 等同样直接估计条件密度，而不把答案压缩成均值[5]。这类方法不需要新标签，但需要数据在邻域内足够密集；如果每个高维图像附近只出现一条专家动作分支，平滑算法也无法知道另一条未观察路线。

4.5 概率输出不能继续只用单点 L1 评价

Gneiting 与 Raftery 研究的是概率预测的评价规则，不是新的动作生成器[4]。严格适当评分规则要求：在真实结果分布下，模型诚实报告该分布时得到最低期望损失。负对数似然可评价完整条件密度，Brier score 可评价二分类成功概率；可靠性图则检查“预测成功率为 0.8”的样本是否约有 80% 实际成功。它不要求改变训练数据格式，但验证集必须包含由同一目标采样过程产生的真实结果。若 Panthera 只保存成功样本，就无法校准 $P(\text{success}|s,a)$ 。

5 改变训练样本：IBC 与 Diffusion Policy 实际做了什么

5.1 IBC 会生成动作负样本

IBC 的网络同时接收观测 o 和候选动作 a ，输出标量能量 $E\theta(o,a)$ 。策略不是网络一次前向直接给出的向量，而是在动作空间中寻找低能量动作：

$$\hat{a} = \arg \min_a E\theta(o,a), \quad p\theta(a|o) \propto \exp(-E\theta(o,a))$$

训练数据中的专家对 (o_i, a_i^+) 是正样本。论文为每个观测生成一组候选负动作 $\{\tilde{a}_{ij}\}$ ，用 InfoNCE 形式让专家动作的能量低于这些候选：

$$L_{\text{IBC}} = -\log [\exp(-E(o_i, a_i^+)) / (\exp(-E(o_i, a_i^+)) + \sum_j \exp(-E(o_i, \tilde{a}_{ij})))]$$

这里确实对数据做了特殊处理，但只是训练时生成对比动作，并没有执行这些动作验证成败[12]。对于“未示范动作也可能正确”的问题，这是一个实质限制：随机负动作中可能混入可行动作，训练却会把它们推向高能量。要避免这一点，需要多正样本、结果标签，或只从已知不可行区域采负样本。

5.2 Diffusion Policy 会切时间窗口并污染动作块

Diffusion Policy 先把示范轨迹整理为滑动窗口。时刻 t 的一条训练记录包含最近 T_o 步观测 O_t 和未来 T_p 步专家动作块 A_t^o 。训练时随机选扩散步 k ，向整段专家动作加入高斯噪声 ϵ^k ，网络预测被加入的噪声：

$$L_{\text{diff}} = \text{MSE}(\epsilon^k, \epsilon\theta(O_t, A_t^o + \epsilon^k, k))$$

部署时从高斯噪声动作块开始，迭代去噪得到 A_t ；只执行前 T_a 步，再读取新观测重新规划[13]。因此，它包含三种数据处理：轨迹归一化、固定长度窗口、训练时噪声污染。这里的高斯噪声只用于教会模型逆向生成专家动作分布，并不表示“加噪后的动作在物理环境中也成功”。Diffusion Policy 能保留示范中已有的多条轨迹，也能让动作块内部保持时间一致，但它不会凭空把专家轨迹周围都标成可行域。

容易混淆的两种“加噪”。 扩散训练把噪声加到数值表示上，目标仍是恢复原专家动作；可行域采集则必须真正把扰动后的状态一动作送入仿真器或规划器，并记录其成功或失败。前者是生成模型训练方法，后者才产生关于物理邻域的新知识。

6 学习可接受输入区域：必须改变监督来源

6.1 条件密度超水平集表示“常见区域”，不自动表示“成功区域”

Camehl、Fok 与 Gruber 的输入是普通随机样本。方法先拟合变量的联合分布，再从中计算条件密度 $f(y|x)$ ，最后寻找阈值 $c_\alpha(x)$ ，使集合

$$C_\alpha(x) = \{y : f(y|x) \geq c_\alpha(x)\}, \text{ 且 } P(Y \in C_\alpha(x)|x) = \alpha$$

包含指定概率质量。论文使用带层级 Dirichlet 先验的过拟合有限高斯混合模型拟合分布，区域可以非凸、分离或多模态[15]；Braun 等进一步研究直接学习最小体积超水平区域[16]。数据本身不需要成功/失败标签，因为论文的目标只是描述观测变量的高密度区域。

若直接把 Panthera 的成功释放状态拿来拟合密度，得到的是“采集程序经常产生的成功状态”，它同时受采样器偏好影响。它不能区分“这个状态没有被采到”和“这个状态执行释放会失败”。要得到允许释放区域，应采集成功和失败结果并估计 $P(\text{success}|s, \text{release})$ ，再对这个函数切阈值。

6.2 Wells：让运动规划器为约一万次查询打标签

Wells 等没有训练动作生成策略。他们把桌面物体的相对位置、尺寸等几何量组成特征，问题标签是指定取放运动能否被规划器解出。训练数据由专门实验生成：两个长方体放在覆盖机械臂可达桌面的 10 cm 网格上；每个问题运行 RRT-Connect 三次，每次最长 30 秒；三次中任一次找到路径就标为可行。最终约一万次查询用于训练带径向基核的支持向量机[10]。

这是一套重新生成的可行性数据集，不是对专家轨迹做增强。分类器只用于给搜索排序，最终仍由运动规划器核验，因此论文允许启发式分类器犯错。它证明规划器可以充当离线标签源，但“超时未找到路径”并不等于数学上不可行，所以标签规则和超时本身构成误差来源。

6.3 Heim：主动收集状态转移和失败，而不是拟合专家动作

Heim 等先定义失败状态集合 S_F 。可生存核 S_V 包含所有“至少存在一种动作能让系统以后持续避免失败”的状态；状态—动作可生存集合 Q_V 包含所有会转移回 S_V 的 (s,a) 。安全度量 $\Lambda(s)$ 是状态 s 下可生存动作切片的体积：体积越大，说明容许的动作越多[11]。

其学习数据来自动执行动作。每次得到 $(s,a,s',failed)$ ，用高斯过程估计状态—动作安全度量，再优先采集对边界最有信息、同时估计风险较低的位置。这不是静态专家示范数据。它与用户思想相近之处是显式度量“一个状态拥有多宽的正确动作集合”；差异是论文目标为无限期避免失败，不是完成圆柱入槽。

6.4 Theile：直接把全部可行动作定义为目标分布

Theile 等给出最接近本问题的形式化。首先定义二值可行性函数和状态条件动作集合：

$$g:S \times A \rightarrow \{0,1\}$$
$$A_s^+ = \{a \in A : g(s,a)=1\}$$

可行性生成器接收状态 s 和潜变量 z ，输出动作 $a=\pi\theta(s,z)$ 。论文要求该映射覆盖 A_s^+ ，并把目标密度定义为可行集合内的均匀分布：

$$p(a|s) = g(s,a) / \int_A g(s,a') da'$$

训练时，一个状态不是只配一个专家动作。生成器先为同一状态提出 N 个动作，再对这些动作加小扰动形成更多查询点；核密度估计用于近似生成器当前的动作密度；可行性函数 g 为每个查询点返回可行/不可行；最后用 Jensen-Shannon、正向或反向 KL 等分布差异更新生成器[14]。因此，损失直接比较“生成动作分布”和“可行集合上的目标分布”，而不是比较某个动作与专家动作的 L1 距离。

当 g 是可并行仿真的解析函数时，可以在线批量查询，无需先固定数据集。当可行性只能通过真实环境实验获得时，论文另训练 critic $\xi\phi(s,a)$ 模仿环境：回放批次一半为可行、一半为不可行，并优先执行 critic 预测接近 0.5、信息量较高的动作。其简化抓取实验使用 128×128 RGB 图像作为状态，动作是平面抓取位置 (x,y) 和角度 α ；模拟器根据夹爪与物体轮廓的相对位置返回确定性的成功/失败。这里最关键的数据变化是反复查询同一状态下的多个动作并保留正、负结果。

最贴近用户想法的方法并不是“把专家数据做平滑”。它先获得一个能回答任意候选 (s,a) 是否可行的函数或 critic，再训练条件生成器覆盖整个可行集合。若没有可行性查询，生成器仍无法知道专家没有选中的动作是否正确。

7 这些研究究竟怎样处理数据集

可以把数据处理分成三个等级。等级一只改变模型和损失：MDN、MCL、CVAE、条件模态回归都可直接使用普通 (x,y) 。等级二改变训练样本的呈现方式：IBC 合成负动作，Diffusion Policy 切动作窗口并加入数值噪声。等级三改变监督来源：Wells 运行规划器打可行标签，Heim 主动采样系统转移，Theile 对同一状态查询多个动作的可行性。只有第三类直接增加了“这个邻域里还有哪些状态—动作成功”的证据。

标准行为克隆观测的是 $s_i \sim d_E$ 和 $a_i \sim \pi_E(a|s_i)$ 。它学习的是专家访问分布 d_E 与专家选择分布 π_E 。即使拟合无限准确，也不能凭空知道专家没有展示的动作是否同样成功。

标准行为克隆观测的是 $s_i \sim d_E$ 和 $a_i \sim \pi_E(a|s_i)$ 。它学习的是专家访问分布 d_E 与专家选择分布 π_E 。即使拟合无限准确，也不能凭空知道专家没有展示的动作是否同样成功。

考虑同一状态只记录到动作 a_1 。下面两个世界对示范数据完全一致：

1. 只有 a_1 可行，其他动作都失败；
2. a_1 、 a_2 、 a_3 都可行，只是专家总偏好 a_1 。

没有额外查询时，任何监督算法都无法区分这两个世界。这不是模型容量不足，而是监督信号不可识别。要估计完整可行域，至少需要下列一种新证据：

- 对状态—动作邻域运行仿真或真机结果试验，记录成功与失败；
- 让运动规划器、碰撞检查器或解析约束充当可行性 oracle；
- 同一状态附近收集多个不同但成功的后继轨迹；
- 提供足够强且可检验的结构假设，例如对已知对称变换保持可行。

DAgger 解决的是另一个相关问题：策略上线后访问自身诱导的状态，专家数据应在这些状态上继续聚合 [6]。PMLR 2011。它能改善闭环分布偏移，却仍默认由专家为访问状态给出动作；如果专家只给一种选择，DAgger 也不会自动标出所有可行选择。

“连续插值”不是充分条件。 流形正则化利用数据几何，鼓励函数沿高密度流形平滑 [2]。JMLR 2006。它可以传播标签，但接触、抓取和释放属于混合动力学模式切换；跨越接触边界时，最优动作或可行集合可能突然改变。只能在经验证的局部区域施加平滑，不能假设整个任务全局光滑。

8 强化学习早已讨论多条正确轨迹，但目标不同

最大熵控制与“控制即概率推断”把高回报轨迹组成概率分布，而不是只保留单个最优轨迹；温度决定分布更集中于高回报解，还是覆盖更多近似最优解 [9]。Levine 2018。所以强化学习确实很早就能表达“多条轨迹都正确”。

不过，标准强化学习的目标通常是最大化期望回报，未必均匀覆盖所有可行解。某条轨迹只要稍微更优，策略就可能集中在那里；熵正则只鼓励分散，不保证覆盖完整可行集合。Theile 等把“先匹配全部可行动作，再在其中优化任务目标”拆成两阶段，正是对这一区别的明确处理。

如果仿真器可以离线接收 (s, a) 并返回成功标签，那么训练 $g(s, a)$ 可归入监督/自监督后训练；如果策略必须通过在线试错才能知道长期结果，并以期望回报更新，那么它就是强化学习。两者边界由标签怎样获得决定，不由网络结构决定。

9 与 Panthera 现有证据怎样连接

现有项目记录已经证实三件事。第一，step 45000 模型在专家记录帧上能在释放窗口输出连续开爪斜坡，自主闭环却可能保持约 0.30 的闭合值。第二，step 65000 的滑动平均闭环能把圆柱稳定送到正确直接释放位，但未触发开爪。第三，专家状态上的验证 L1 下降不能预测闭环成功率。这些证据见项目内的单轨迹过拟合门禁记录和动力学 proprio 实验。

这些事实与“训练只看到狭窄专家状态—动作轨迹”相容，但尚不能证明连续可行域学习一定解决释放。至少还有三种替代解释：图像与 28 维本体状态仍不足以辨认接触阶段；动作 chunk 重叠执行造成闭环固定点；训练器、数据或模型容量仍使策略没有充分拟合。DDP 修复后的实验也说明历史三卡结果必须谨慎解释，见多卡 action head 同步修复。

现象	连续可行域假设的解释	必须排除的替代解释
到达槽上方仍闭合	自主状态落在训练轨迹旁边；模型只学到专家轨迹上的开爪触发线，而没有学到一片可释放区域	状态不可观测、时间阶段缺失、执行聚合抑制、训练不足
接近圆柱时抖动	多个绕行/接近方向被逐点回归平均，或相邻查询在多种模式间切换	旧 chunk 对齐、控制频率、DDP 历史故障、碰撞与动力学
持物搬运相对稳定	该段可行轨迹管道较宽，状态—动作成功场对局部偏差更宽容	只在已审阅 episode 2 成立，不能外推为普遍规律

当前只是可检验解释。 文献没有直接研究 Panthera 的同一故障。报告提出的是一个比“单帧到唯一动作”更合理的建模框架，而不是已经完成的根因证明。

10 建议的监督后训练实验

10.1 先建立 release feasibility arena

先不重训完整 VLA。围绕 episode 2 的释放位建立连续状态采样器，变量至少包含：

- 圆柱相对槽中心的三维位置、轴向角误差和线/角速度；
- 末端相对圆柱/槽的位姿、六关节位置/速度/加速度/载荷；
- 夹爪实际开度、圆柱是否随夹爪运动、手指接触状态；
- 小幅相机位置、俯视角、光照和渲染扰动，但不改变任务物理标签。

使用 Sobol 或拉丁超立方采样覆盖连续邻域，不只在规则网格上取点。对每个状态执行固定的释放—沉降—检查流程，并对物理微扰重复若干次，记录稳定入槽概率。采集不依赖墙钟 `sleep`，以物理步和成功/失败事件推进。

10.2 每条数据应记录什么

Panthera

不应把现有成功专家轨迹复制若干次后称为连续可行域数据。一次查询应先从人为规定的提议分布 $\mu(s,a)$ 中抽取物理状态和候选动作块，再由仿真结果写标签。建议每条记录至少包含：

字段	内容	用途
state_privileged	圆柱、槽、末端、关节、夹爪、接触和速度等仿真真值	先验证物理状态上是否真的存在可学习的连续成功区域
observation	策略 RGB、28 维 proprio、相机参数和时间戳	随后训练可部署观测模型；不得把仿真特权量暗中作为部署输入
action_chunk	完整 25×7 候选动作块及其控制语义	把左/右修正、下降、松开、撤离作为连贯轨迹评价，避免逐帧混合
outcome	稳定入槽、合法释放、提前释放、仍夹持、碰撞和超时	提供可行性正、负标签并区分失败原因
repeat	同一名义 (s,a) 下的物理随机 seed、成功次数 k 和总次数 n	用 k/n 估计随机动力学下的成功概率，而非把一次偶然结果当真值
proposal	状态/动作采样器版本、范围和采样密度或可重放 seed	区分“采得多”与“成功率高”，并支持重要性加权或重新采样

相机增强应对同一物理状态渲染多个视角、光照和纹理，并继承同一个物理结果标签；它训练的是观测不变性。物理状态扰动则必须重新执行动作并重新判定结果；不能假定邻近位置自动继承专家标签。训练、验证和测试也应按物理场景与随机 seed 分组，不能把同一次 rollout 的相邻帧拆到不同集合，否则会高估泛化。

10.3 学习成功概率场，而不是先学习动作

训练校准的 $g_{\text{release}}(s)=P(\text{success}|\text{release at } s)$ 。第一版直接读取仿真物理状态，以验证数学假设；第二版再用策略可获得的 RGB 与 28 维 proprio 预测同一概率。验收同时报告：

- 负对数似然、Brier score、可靠性图和预期校准误差；
- 阈值集合 S_τ 的精确率、召回率与边界附近错误；
- 在未见扰动 seed 和相机位姿上的稳定入槽率；
- 特权状态模型与可部署观测模型的差距。

10.4 再学习集合内的多解轨迹

从同一释放邻域，用规划器或扰动 oracle 生成多条成功动作块：不同接近高度、左右微调、下降—松开—撤离曲线都可以保留，只要最终物理结果合格。模型候选按成本从低到高为：混合密度头、条件变分模型、隐式能量策略、动作扩散模型。当前 OpenVLA-OFT 的连续 L1 头可作为点估计基线，不能直接冒充分布基线。

策略目标可以写成一个被可行性加权的分布：

$$\pi(a|s) \propto p_0(a|s) \exp(\beta \cdot g(s,a)), \text{ 或显式要求 } \text{support}(\pi) \subseteq A_\tau(s)$$

执行时每次采样一条完整动作块并保持其模式一致，不能每帧独立在“向左”和“向右”之间抽样，否则正确的多模态会变成抖动。滚动重规划时仍需要当前项目正在调查的旧 chunk 对齐与历史条件，但它属于时间一致性轴，不替代可行域学习。

10.5 最小对照

组别	训练信号	回答的问题
F0	现有单轨迹逐点 L1	离散专家点基线
F1	专家邻域增强，但仍只回归唯一动作	仅扩大输入覆盖是否足够
F2	成功/失败监督的 $g(s,a)$ + 单一可行动作选择	显式可行性是否改善释放触发
F3	$g(s,a)$ + 多解条件轨迹分布	覆盖多条正确路线是否进一步降低抖动和失败
F4	F3 + 旧 chunk/动作历史一致性	可行域与时序一致性是否互补

各组使用同一状态采样、相机 seed、动作预算和闭环初始条件。主要结果是完整任务成功、给定到位后的合法释放率、过早释放率、到位仍夹持率、碰撞冲量和动作 jerk；分布模型另报告覆盖与校准。必须保留失败标签，否则模型只会重建成功样本密度，无法知道边界在哪里。

11 什么结果会否定这个想法

以下任一结果都应促使项目放弃或收窄该路线：

1. 特权物理状态上的成功概率场都无法在未见扰动中校准，说明采样、标签或动力学随机化定义有问题；
2. F2 相比 F0/F1 不提高到位后的合法释放率，说明“缺少连续释放区域监督”不是主要瓶颈；
3. F3 的分布覆盖提高，但闭环抖动或成功率不改善，说明多解输出不是当前抖动根因；
4. 特权状态 F2/F3 成功、RGB+proprio 版本失败，说明主要限制是观测可辨识度，而不是动作表示；
5. 只有加入显式阶段或时间历史才成功，说明当前单帧观测不满足 Markov 条件，应转向层级/记忆模型。

这些否定条件很重要：前人工作提供方法候选，不构成 Panthera 的硬约束。即使数学框架正确，工程收益也必须由闭环消融决定。

12 结论

用户的核心判断成立，但需要精确拆分：输入侧应学习的是连续状态上的成功概率或可接受集合；输出侧应学习的是给定状态下的可行轨迹支持及其条件分布。两者共同形成状态—动作空间上的成功结构。普通专家示范只给出该结构中的稀疏选择点，无法识别全部可行域。

这一路线不必立即进入强化学习。Panthera 已有仿真器，可以通过离线状态扰动、动作查询和结果检查建立监督数据。最小合理下一步不是直接替换成扩散模型，而是先建立并验证释放成功概率场；只有确认附近确实存在宽广且可观测的成功区域后，再训练覆盖多个可行轨迹的生成式动作策略。

报告边界。 本报告完成了文献归档、数学对象澄清和实验设计，没有执行 release arena 采样、后训练或闭环评测。现有 Panthera 故障与该理论之间仍是待验证假设。

参考文献

- [1] C. M. Bishop, “Mixture Density Networks,” NCRG/94/004, 1994. Microsoft Research.
- [2] M. Belkin, P. Niyogi, and V. Sindhwani, “Manifold Regularization: A Geometric Framework for Learning from Labeled and Unlabeled Examples,” JMLR, 2006. JMLR.
- [3] J. Einbeck and G. Tutz, “The Fitting of Multifunctions: An Approach to Nonparametric Multimodal Regression,” COMPSTAT, 2006. Durham Repository.
- [4] T. Gneiting and A. E. Raftery, “Strictly Proper Scoring Rules, Prediction, and Estimation,” JASA, 2007. PDF.
- [5] M. Sugiyama et al., “Conditional Density Estimation via Least-Squares Density Ratio Estimation,” AISTATS, 2010. PMLR.
- [6] S. Ross, G. Gordon, and D. Bagnell, “A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning,” AISTATS, 2011. PMLR.
- [7] A. Guzmán-Rivera, D. Batra, and P. Kohli, “Multiple Choice Learning: Learning to Produce Multiple Structured Outputs,” NeurIPS, 2012. NeurIPS.
- [8] K. Sohn, H. Lee, and X. Yan, “Learning Structured Output Representation using Deep Conditional Generative Models,” NeurIPS, 2015. NeurIPS.
- [9] S. Levine, “Reinforcement Learning and Control as Probabilistic Inference: Tutorial and Review,” arXiv:1805.00909, 2018. arXiv.
- [10] A. M. Wells et al., “Learning Feasibility for Task and Motion Planning in Tabletop Environments,” IEEE RA-L, 2019. Kavradi Lab.
- [11] S. Heim et al., “A Learnable Safety Measure,” CoRL, 2020. PMLR.
- [12] P. Florence et al., “Implicit Behavioral Cloning,” CoRL, 2022. PMLR.

- [13] C. Chi et al., “Diffusion Policy: Visuomotor Policy Learning via Action Diffusion,” IJRR, 2024. 项目页.
- [14] M. Theile et al., “Learning to Generate All Feasible Actions,” IEEE Access, 2024. arXiv.
- [15] A. Camehl, D. Fok, and K. Gruber, “On Superlevel Sets of Conditional Densities and Multivariate Quantile Regression,” Journal of Econometrics, 2025. DOI.
- [16] S. Braun, M. I. Jordan, and F. Bach, “Super-Level-Set Regression: Conditional Quantiles via Volume Minimization,” arXiv:2605.06210, 2026. arXiv.

项目内证据索引

- docs/22_single_trajectory_overfit_gate_hardening_2026-09-20.md: 专家帧释放斜坡、闭环到位不松爪和聚合 L1 的限制。
- docs/24_openvla_dynamics_proprioception_overfit_2026-09-21.md: 7/28 维 proprio 合同与动力学状态实验边界。
- docs/25_openvla_action_head_ddp_sync_fix_2026-09-23.md: 历史三卡 action head 分叉及修复后实验解释边界。
- docs/26_hierarchical_skill_transition_literature_review_2026-09-24.md: 阶段条件、终止提议与验证器的另一条候选路线。
- docs/27_openvla_rl_release_reward_design_2026-09-24.md: 结果奖励、release arena 和跨 chunk 一致性的强化学习方案。
- docs/references/continuous_feasible_distribution_papers.md: 16 篇本地论文原文、来源和 SHA-256。